

機器學習期末專題：特徵選擇方法比較研究

A Comparative Study on Feature Selection Methods in Machine Learning

國立中興大學應數系大數據在職專班

鄭榮明 ID:5112053018

GitHub 專題連結: <https://github.com/cheng-jung-ming/ML-Feature-Selection-Project>

摘要

在 2024 年底，歐盟通過全球首部 AI 框架法案，強調人工智慧系統的透明性與可解釋性。在機器學習應用中，特徵選擇 (Feature Selection) 不僅是提升模型效能的關鍵步驟，也對模型的解釋能力具有深遠影響。許多企業在數據分析時，期望模型能準確預測，並同時理解影響預測結果的核心特徵，以促進實務決策。

本研究整合多種特徵選擇方法與可解釋性工具，並參考五篇關鍵文獻，涵蓋跨模型特徵重要性整合 (Fisher et al., 2019)、SHAP 博弈理論基礎 (Lundberg and Lee, 2017)、基於注意力機制的 TabNet 模型 (Arik et al., 2021)、FK-RFE 特徵篩選策略 (2023)、以及子群組條件重要性估計的 cPFI 技術 (2023)。在實作方面，以 Kaggle 公開資料集「電信客戶流失預測」為例，展示融合 TabNet 與 SHAP 的可解釋性分析流程，發現模型能有效指出潛在高風險客戶群體與影響其預測結果的關鍵特徵組合，證實本研究方法在實務場景中具備應用潛力。

綜合以上，本文提出一套融合 PFI、SHAP、FK-RFE 與 TabNet 等策略的機器學習流程，兼顧準確性與解釋性，期望為特徵選擇技術提供系統性與實務導向的應用參考。

Index Terms

機器學習、特徵選擇、SHAP、TabNet、FK-RFE、cPFI、可解釋性

1 緒論

隨著人工智慧技術日益成熟，其應用場景不再僅限於提升預測準確率，更逐漸強調「模型可解釋性 (Model Interpretability)」。特別是在醫療、金融、客服等領域，模型所做出的預測結果，若無法說明「為何」會產生，將難以取得使用者信任或落實實務應用。歐盟於 2024 年底通過的 AI 框架法案，亦明確指出高風險 AI 系統須具備可解釋性機制。

在機器學習中，「特徵選擇」是與可解釋性關聯最緊密的步驟之一。透過有效的特徵選擇方法，不僅能提升模型效能、減少過擬合，也能協助我們理解資料中哪些變數對預測最為關鍵。然而，現有特徵選擇方法各有優劣：有些方法依賴特定模型內部機制，易產生偏誤；有些則缺乏對變數間交互關係的考量。

本研究綜合多篇重要文獻，設計一套融合傳統方法與進階模型的重要性評估機制，建立具備效能與可解釋性的混合式特徵選擇流程，分為以下三個階段：

• 第一階段：集成初步核心特徵。採用三種常見

的重要性評估方法——隨機森林內部的 feature importance、Permutation Feature Importance (PFI)、以及 SHAP 值之全局貢獻度，分別選出高重要性特徵後進行集成，以交集為基礎，補齊至固定維度，形成初步的核心特徵組合。本階段以隨機森林 (Random Forest) 作為基準模型，驗證各方法下的準確率與穩定性。

- 第二階段：改良方法進行獨立篩選。引入兩種改良型方法，分別對全體特徵集進行獨立選擇：其一為條件式 PFI (cPFI)，透過特徵子群的條件重抽樣方式考量變數間相依性；其二為基於穩健性原則之 FK-RFE，結合遞迴特徵刪除與多次隨機重抽以提升篩選穩定性。此階段同樣以隨機森林為統一基準，用意在於比較「傳統方法」的集成策略，與文獻提供改良型方法進行模型性能比較。
- 第三階段：集成最終特徵組合與深度模型比較。綜合第一階段之初步核心特徵、cPFI 結果、FK-RFE 結果，以及 TabNet 模型內部自動選擇之重要特徵，進行第二次集成。先取四者交集，再以此為起點，

以貪婪算法逐步加入特徵補齊至固定維度，建立最終特徵組合。最終將此組合作為 TabNet 的輸入特徵，與 TabNet 自身選擇特徵進行效能與結構層面的比較，作為深度模型可解釋性之延伸探討。

2 文獻探討

特徵選擇與模型可解釋性一直是機器學習領域中的關鍵課題，尤其在應用導向日益明確的當下，如何有效識別重要特徵、提升預測效能並兼顧解釋性成為研究熱點。以下將介紹五篇與本研究密切相關的代表性文獻，涵蓋傳統機制、深度學習架構，以及近期針對特徵依賴性與選擇穩定性所提出的改良方法，作為本研究方法設計的重要依據。

2.1 模型整合觀點的特徵重要性學習

Fisher et al. (2019) 在《Journal of Machine Learning Research》發表的研究”All models are wrong, but many are useful”提出了一種橫跨多種模型架構的特徵重要性分析方法 [1]，強調由多模型共同學習特徵重要性可有效降低單一模型偏好所帶來的偏誤。此篇文獻對本研究所採集成式特徵選擇策略的發展具有啟發意義。

2.2 博弈論基礎的模型解釋工具：SHAP

Lundberg and Lee (2017) 在 NeurIPS 發表的”A unified approach to interpreting model predictions”，提出了 SHAP (SHapley Additive exPlanations) 方法 [2]，基於博弈論中 Shapley 值的理論，提供一致性與局部可加性的特性，使得模型解釋更具數學嚴謹性與實用性。SHAP 已成為當前最廣泛應用的模型解釋方法之一。

2.3 注意力機制於表格資料的應用：TabNet

Arik and Pfister (2021) 在 TabNet: Attentive Interpretable Tabular Learning 中，提出一種專為結構化表格資料設計的深度學習架構 [3]。該模型結合注意力機制與順序特徵選擇機制 (sequential attention)，能在訓練過程中學習特徵重要性，同時提供良好的可解釋性，適用於無需大量前處理的表格型任務。

2.4 篩選與遞迴結合的混合特徵選擇方法：FK-RFE

Zhang et al. (2023) 提出一種結合 Kolmogorov filter 與隨機森林遞迴特徵消除 (FK-RFE) 的混合式特徵選擇流程 [4]。該方法首先透過 Kolmogorov 濾波器，根據每個特徵對於目標變數的分布差異進行排序，篩選出初

步特徵子集。其後，透過隨機森林模型進行特徵重要度遞迴式評估，逐步消除貢獻度較低者。該流程無需模型假設，兼具前期效率與後期精緻性，對中高維分類任務表現出良好穩定性與可解釋性。

2.5 處理特徵依賴性的條件重要性方法：cPFI

2024 年文獻 Model agnostic feature importance and effects with dependent features: a conditional subgroup approach, 則針對傳統 PFI (Permutation Feature Importance) 在特徵具高度依賴性時易產生錯誤評估的問題，提出條件子群 (conditional subgroup) 技術 [5]。該方法透過決策樹建構具代表性的特徵子群，從而進行有條件的特徵重要性估計。本研究在實作中以隨機森林替代決策樹進行子群劃分，進一步提升穩定性與可解釋性。

3 研究方法

本研究旨在建構一套融合多種特徵選擇技術的混合式流程，以兼顧機器學習模型之效能與可解釋性。由於不同方法對特徵重要性的評估角度各異，單一方法可能導致偏誤，因此本研究整合隨機森林內部結構、SHAP 值之解釋能力、遞迴特徵消除 (RFE) 之穩健性與 TabNet 深度特徵抽取能力，設計一套層次式、多階段的特徵選擇流程。整體流程如圖 1 所示。




圖 1: 特徵選擇研究流程

3.1 數據說明

使用來自 Kaggle 公開資料集「Telco Customer Churn」之數據，如圖 2 所示。該數據集包含 20 個自變數與 1 個目標變數，變數說明如表 1 所列。




圖 2: 資料來源畫面截圖

變數類別	變數名稱
自變數	customerID, gender, SeniorCitizen, Partner, Dependents, tenure, PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies, Contract, PaperlessBilling, PaymentMethod, MonthlyCharges, TotalCharges
目標變數	Churn

表 1: 資料集變數說明

3.2 實驗設計

整體實驗流程如圖 3 所示，主要分為以下幾個階段：資料集選定、資料預處理、建構全特徵基準模型 (Baseline)、進行特徵選擇、重新訓練模型、評估並比較模型效能。為聚焦於特徵選擇技術本身，資料預處理僅進行簡易補值與清理，並未採用複雜轉換或特徵工程手法。接著依序套用多種特徵選擇方法，並以集成方式篩選具代表性的變數，並利用機器、深度學習模型（如隨機森林、TabNet 等）進行訓練與預測。最後以多項效能指標（如 Accuracy、F1-score 等）進行比較，最終以最佳特徵組合及最佳模型進行 SHAP 分析，以探討模型決策邏輯與特徵重要性。




圖 3: 本研究整體實驗流程圖

4 實驗結果

本章將針對各種特徵選擇策略下所訓練之模型進行效能比較與分析，評估其在電信客戶流失預測任務中

的適用性與實用性。首先，我們以隨機森林 (Random Forest, RF) 模型在「全特徵輸入」情境下建立基準模型 (Baseline)，作為後續比較的參考基準。該模型未進行任何特徵篩選，直接以完整的 20 個自變數進行訓練與預測，並採用準確率 (Accuracy)、精確率 (Precision)、召回率 (Recall) 與 F1 分數 (F1 Score) 四項指標作為評估依據，如表 2。

評估指標	數值
Accuracy	0.7935
Precision	0.6519
Recall	0.4718
F1 Score	0.5474

表 2: 全特徵 RF 模型效能 (Baseline)

4.1 特徵數量

在進行特徵選擇之前，必須先釐清所需特徵數量，方能在模型效能與特徵維度之間取得平衡。為此，本研究採用遞迴特徵消除 (Recursive Feature Elimination, RFE) 方法，繪製特徵數量與模型 Accuracy 之關係曲線，以觀察重要特徵的累積效果。如圖 4 所示，Accuracy 分數在納入前兩個特徵時即快速上升，隨後雖持續提升，但增益幅度逐漸遞減，顯示邊際效益下降。

考量本研究需比較多組特徵組合，並兼顧模型效能與可解釋性，最終選定前 8 個特徵作為後續實驗分析之基礎。

基於此分析結果，為在模型效能與複雜度間取得平衡，本研究最終選擇前 8 個重要特徵作為後續各特徵選擇策略與模型訓練的共通基準。此舉不僅有助於降低過擬合風險，亦提升模型在實務部署中的可行性與解釋力。

4.2 集成特徵

在前述特徵數量確定為 8 項後，本節進一步探討不同特徵選擇方法所產出的變數組合，並嘗試整合其優勢以建立最終模型。本研究先選用三種方法進行特徵篩選，分別為隨機森林內部特徵重要性 (RF Importance)、置換特徵重要性 (Permutation Feature Importance, PFI) 以及 SHAP 值 (SHapley Additive exPlanations)。每種方法皆選出其排名前八之特徵，如表 3 所示。

為整合三種方法之結果，並兼顧模型效能與變數解釋性，本研究採用類似貪婪演算法 (Greedy Algorithm) 之逐步選擇策略。首先取三種方法之交集特徵作為基




圖 4: RFE 特徵數量與 Accuracy 關係

方法	特徵名稱
PFI	tenure
	InternetService_Fiber optic
	MonthlyCharges
	Dependents
	PaymentMethod_Electronic check
	Contract_Two year
	DeviceProtection
SHAP	SeniorCitizen
	tenure
	InternetService_Fiber optic
	Contract_Two year
	TotalCharges
	PaymentMethod_Electronic check
	MonthlyCharges
RF 內部指標	InternetService_No
	Contract_One year
	TotalCharges
	MonthlyCharges
	tenure
	InternetService_Fiber optic
	PaymentMethod_Electronic check
	Contract_Two year
	gender
	PaperlessBilling

表 3: 不同方法選出之 8 個特徵集整表

礎，接續優先納入 SHAP 與 RF 之共同特徵、RF 單獨選出之關鍵變數，以及 SHAP 獨有但具解釋價值之特徵。我們以 Venn 圖來表示，如圖 5。

取出交集並完成逐步選擇達到 8 個最佳特徵組合後，如表 4 所示，我們進一步比較各階段 RF 模型效能，如表 5，RF、SHAP 各自選擇之特徵組表現相近，而集成特徵模型在 F1 分數上達到最佳值 0.5677，顯示整合多種特徵選擇策略可有效提升模型效能與穩定性。

Feature Selection Comparison (PFI vs SHAP vs RF)



圖 5: PFI、SHAP、RF 三種特徵選擇法之 Venn 圖

特徵名稱	來源說明
tenure	三法交集
InternetService_Fiber optic	三法交集
MonthlyCharges	三法交集
PaymentMethod_Electronic check	三法交集
Contract_Two year	三法交集
TotalCharges	SHAP 與 RF 交集
SeniorCitizen	RF 獨有
Contract_One year	SHAP 獨有

表 4: 最終選定之 8 項集成特徵

4.3 優化方法

在前節中，我們結合隨機森林內部重要性、PFI 與 SHAP 三種傳統特徵選擇方法，並取其交集作為整合策略，回應 Breiman 提出的經典觀點：「All models are wrong, but many are useful.」此集成方法在效能與穩健性之間取得一定平衡。

為進一步提升特徵選擇的品質與模型效能，這裡導入兩種近年提出的改良方法作為優化策略：**FK-RFE** 與 **cPFI**。這兩種方法分別延伸自隨機森林內部指標與 PFI 方法，旨在克服傳統方法於特徵依賴性與樣本異質性方面的限制。

模型	Accuracy	Precision	Recall	F1 Score
Baseline	0.7935	0.6519	0.4718	0.5474
PFI 特徵組合	0.7601	0.5559	0.4665	0.5073
SHAP 特徵組合	0.7771	0.5949	0.4960	0.5409
RF 內部特徵	0.7864	0.6208	0.4960	0.5514
集成 8 特徵	0.7871	0.6137	0.5282	0.5677

表 5: 不同特徵組合之模型效能比較

- **FK-RFE** (Filter + Kernel-RFE) 首先以 Kolmogorov 濾波器進行特徵初篩，剔除與目標變數無關的特徵，接著透過隨機森林進行遞迴式消除，具備較佳的抗干擾性與效能穩定性。
- **cPFI** (Conditional Permutation Feature Importance): 本方法源自 Hooker 等人提出的 conditional permutation 重要度概念，惟其原始設計以單棵決策樹劃分子群，實作時易產生過擬合與不穩定性問題。為改善此情況，本研究改以隨機森林進行子群劃分，透過多棵樹之集成特性建構出更穩定的條件子群，再於各子群內分別計算 permutation importance，並整合不同條件下的結果，以篩選出於多樣樣本條件下皆穩定貢獻之特徵，提升特徵選擇之可靠性與可解釋性。

本節將呈現 FK-RFE 與 cPFI 之效能與選擇結果，如表 6 及表 7

方法	Accuracy	Precision	Recall	F1 Score
FK-RFE	0.7800	0.6013	0.5013	0.5468
cPFI	0.7693	0.5714	0.5147	0.5416

表 6: 不同特徵選擇方法之精簡模型效能比較

方法	所選特徵
FK-RFE	gender, tenure, PaperlessBilling, MonthlyCharges, TotalCharges, InternetService_Fiber optic, Contract_Two year, PaymentMethod_Electronic check
cPFI	TotalCharges, tenure, InternetService_Fiber optic, SeniorCitizen, gender, MultipleLines, PaperlessBilling, PaymentMethod_Electronic check

表 7: 各方法所選特徵比較

綜合 4.2 及 4.3 節各種特徵選擇方法的比較，從模型效能指標來看，以 F1 分數作為主要評估標準，集成 8 特徵組合的表現最佳，達到 0.5677。

4.4 深度學習模型：TabNet

TabNet 為 Google 於 2019 年提出之可解釋深度學習模型，專為表格型結構化資料 (tabular data) 所設計。其模型核心架構融合注意力機制 (attention) 與決策步驟 (decision steps)，透過 sequential attention 使模型在每一步動態選擇最具貢獻的特徵進行計算，進而形成具 sparsity 的決策路徑，兼具可解釋性與建模能力。此設計不同於傳統全連接神經網路對所有特徵進行平等處理，能有效提升對異質特徵的建模效果。

儘管 TabNet 在國際上逐漸受到關注，但目前於國內尚屬罕見應用，尤其在學術研究與業界實務中，多仍以傳統機器學習模型 (如隨機森林、XGBoost 等) 作為表格數據建模主體。因此，本研究特別引入 TabNet 作為深度學習代表模型，除與傳統機器學習模型進行模型效能比較外，亦藉由其內建注意力結構進行特徵選擇分析。

在特徵選擇上，TabNet 透過每層的 Feature Mask 動態決定參與計算之特徵，模型訓練完成後可彙總各特徵於多層決策步驟中被選擇的頻率，進而形成特徵重要度排序。由於此選擇機制具資料驅動與非線性特徵組合之特性，理論上具備較傳統模型更強之特徵辨識能力。

本節中，我們以 TabNet 為基礎，訓練分類模型並擷取其特徵 mask，取得特徵重要性後進行排序 (所選特徵與模型效能如表 8)，取前 8 名作為重要特徵，並與第一階段所得之三組特徵組合——傳統集成特徵、FK-RFE、cPFI——進行交集運算。最終產出四法交集的特徵集合 (如圖 6 所示)，並以該集合為起點，搭配貪婪演算法逐一加入剩餘候選特徵，直至達到 8 個特徵為止，形成最終的集成特徵組合。

此特徵組合將再次輸入 TabNet 模型進行訓練與預測，以評估其在深度學習架構下是否能較傳統方法達成更佳之分類表現，亦作為本研究混合式特徵選擇流程實務效益之驗證。

內容	結果
所選特徵	Dependents, OnlineSecurity, InternetService_No, Payment-Method_Mailed check, Contract_One year, MonthlyCharges, tenure, Contract_Two year
模型效能	Accuracy: 0.7942, Precision: 0.6590, Recall: 0.4611, F1 Score: 0.5426

表 8: TabNet 所選特徵與模型效能

4.5 混合式特徵選擇結果與模型驗證

綜合傳統機器學習模型 (以隨機森林為代表) 所建立的特徵交集策略、以及 FK-RFE、cPFI 三種特徵選擇方法，本研究將前三組特徵組合與 TabNet 模型訓練後所得之特徵進行四方交集，僅發現一個共同特徵 **tenure**。此現象顯示不同模型架構下對於特徵的偏好存在明顯差異，進一步呼應 Box 所提出的觀點：「All models are wrong, but many are useful.」每一種模型因其內部結構與演算法設計，在特徵選擇時會展現出不同




圖 6: 四種特徵組合交集 Venn 圖

的「喜好」與「盲點」，正因如此，多模型、多方法交互驗證的混合式流程方能發揮其價值。

在四方交集的基礎上，我們以貪婪演算法逐步引入 TabNet 所排序之剩餘候選特徵，直至形成 8 個特徵的最終集成特徵組合，並再次以 TabNet 架構進行模型訓練與驗證。結果顯示，使用該精選特徵組合所訓練之 TabNet 模型相較於傳統方法表現更佳，在分類效能上全面超越 FK-RFE 與 cPFI 等特徵選擇組合，亦優於原始 TabNet 選擇組合（見表 9）。

特徵組合	Accuracy	Precision	Recall	F1 Score
最終精選特徵（本研究）	0.8126	0.6730	0.5684	0.6163
FK-RFE	0.8091	0.6667	0.5576	0.6073
cPFI	0.8077	0.6821	0.5121	0.5850
傳統集成特徵	0.8091	0.6831	0.5201	0.5906
TabNet 原生選擇	0.7942	0.6590	0.4611	0.5426

表 9: 不同特徵組合在 TabNet 上之模型效能比較

本研究所提出之混合式特徵選擇流程，成功整合傳統機器學習與深度學習模型之優勢，在保留模型可解釋性的同時，亦展現良好之分類效能，證明此方法在實務應用中具備潛力。

5 SHAP 的延伸應用：從模型效能到決策洞見

在前幾章中，我們探討了多種特徵選擇方法，並以混合式流程融合其優勢，有效提升模型效能。然而，機器學習模型的價值並不僅止於分類準確率的提升，更重

要的是能否從數據中挖掘出具備實務價值的資訊，進而輔助企業決策，解決實際問題。

在此章中，我們不再以「哪一種特徵最好、哪一種方法最準」為出發點，而是轉向更進一步的問題：「模型選擇這些特徵，代表了什麼？」、「這些特徵如何影響模型預測？」、「這些規律對企業有何啟示？」。為此，我們選擇以 SHAP（SHapley Additive exPlanations）作為主要解釋工具，針對最終訓練完成的 TabNet 模型進行模型可解釋性分析與資料探勘（Data Mining），試圖從中提煉出潛藏於數據中的行為模式與潛在風險因子。

5.1 SHAP Dependence Plot

SHAP 依賴圖（dependence plot）是解釋模型的重要工具，能揭示某一特徵的原始數值與其對模型預測影響（SHAP 值）之間的關係。依賴圖亦可透過顏色映射其他變數的取值，觀察變數間的交互作用，適合進行多維關聯性分析與策略推導。圖 7 顯示以 TabNet 模型繪製的依賴圖，呈現多個對客戶流失影響顯著的特徵，如合約類型、網路服務、使用月數、月費與總費用等。為提升模型結果的可應用性，本文進一步設計兩個典型用戶案例「曾世強」與「Anna」（詳見表 10），從模型解釋延伸出具體的行銷策略建議。




圖 7: SHAP 依賴圖：呈現重要變數對流失預測之貢獻與交互關係

以下聚焦於三個最具代表性的變數：月費（MonthlyCharges）、總費用（TotalCharges）與使用月數（tenure），深入說明其對預測結果的貢獻模式與交互效應。MonthlyCharges（月費）：依賴圖中的 LOESS 曲線整體呈現上升趨勢，特別是在月費超過 65 美金後，SHAP 值明顯上升，顯示高月費用戶的流失風險較高。圖中尾段 SHAP 值分布呈現紅藍交錯，反映高月費用戶中存在顯著的兩極化現象——一部分為高付費但實際流失的關鍵客群，須特別關注。

項目	曾世強：新用戶	Anna：老用戶
基本特徵	28 歲工程師 無綁約、光纖用戶 月費 1900 元 使用 3 個月	年資 8 年 兩年長約、服務全包 月費 2800 元
SHAP 解讀	無綁約具高風險 光纖+高月費 SHAP 上升 使用期短，黏著度低	長期用戶風險低 高總費用呈 U 型結構 疲乏與價格敏感浮現
策略建議	建立信任關係 引導轉長約	推出資深回饋方案 優化資費以降風險

表 10: 典型用戶情境與 SHAP 解釋摘要

TotalCharges (總費用): SHAP 值的變化呈現 U 型結構，當總費用低於 4000 美金時，預測貢獻值多為負向，顯示該群客戶流失風險較低；但當總費用超過 4000 元，SHAP 值轉為正向，反映高資費客戶對價格疲乏或對價值認知下降的狀況。

tenure (使用月數): 整體呈負相關趨勢，支持「使用越久、流失風險越低」的直覺。然而在尾段區間，SHAP 值仍出現紅藍分明的分布，表示即使是長期用戶，若搭配高資費，仍有潛在流失風險。這提示企業應針對忠誠用戶設計更細緻的分群行銷策略。綜合上述分析，SHAP 依賴圖不僅揭示模型對特徵的預測敏感度，亦能結合交互變數提供策略洞察，是連結 AI 預測與實務決策的重要橋樑。

5.2 SHAP Waterfall Plot

SHAP 瀑布圖 (Waterfall Plot) 為逐個特徵視角的可視化工具，能夠清楚展現單一標本中各變數的 SHAP 值貢獻，如何由基準值 (baseline) 逐步推移至模型的最終預測值，適合剖析模型的預測邏輯與錯誤來源。

圖 8 所示為一筆模型誤判為「不流失」但實際上發生流失 (False Negative) 的典型標本，其特徵包含：老用戶 (tenure = 68)、使用光纖網路、月費高達 89.6 元，總費用達 6127.6 元，且採用電子帳單。根據模型解釋，最具影響力的特徵為：

- **tenure = 68**: 模型根據長期用戶經驗，對此特徵給予明顯負向 SHAP 值，認為該用戶「應不會流失」，為本案例預測錯誤的主因。
- **TotalCharges = 6127.6、MonthlyCharges = 89.6**: 均為偏高水準，依據第 5.1 節對 SHAP 依賴圖的分

析，高費用用戶在模型中呈現正向貢獻，意即具有較高的流失傾向。

- **InternetService_Fiber optic = 1**: 亦為正向貢獻，反映光纖用戶的流失風險高於一般用戶。
- **Contract_Two year = 0 與 PaperlessBilling = 1**: 顯示用戶未綁長約，且習慣電子帳單，可能代表其對業者黏著度較低，亦支持潛在流失風險。

整體而言，雖然多數變數已給出明顯流失訊號，但模型因對 **tenure** 特徵的高度信任，產生「老客戶不會流失」的過度樂觀判斷，最終導致錯判。此案例顯示即使為忠誠用戶，若資費水準過高、缺乏長約保障，仍可能形成潛在風險。這樣的分析有助於企業針對模型誤判進行風險調整與行銷策略微調，例如：

- 強化資深高資費用戶之滿意度調查與價值再定位。
- 結合多重特徵進行異常行為偵測，降低對單一變數的依賴。




圖 8: SHAP 瀑布圖：模型錯誤預測之個案解析 (tenure 拉低預測值)

6 結語

本報告針對電信客戶流失預測任務，提出融合多種方法的混合式特徵選擇流程，兼顧模型效能與解釋力，並透過 SHAP 可視化深入剖析模型邏輯。實驗結果顯示，透過 SHAP 與 TabNet 等工具，我們不僅能提升模型預測的準確度，也能有效掌握錯誤預測的關鍵原因。

本研究進一步驗證，特徵選擇在可解釋人工智慧 (XAI) 中佔據關鍵地位。良好的特徵選擇策略能有效提升模型的抗噪性 (noise robustness)、降低維度詛咒 (curse of dimensionality) 影響，並強化模型的表示能力與泛化能力。更重要的是，僅保留具高貢獻與業務意涵的特徵，不僅可提升預測效能，也使後續的模型解釋更具一致性與可行性。唯有建立在高品質特徵之上的學習流程，方能同時達成性能優化與決策透明的雙重目標。

從一筆誤判樣本出發，我們觀察到 tenure 特徵的過度貢獻可能導致模型低估用戶流失風險，顯示即使是表現良好的模型，仍須持續進行結果解釋與風險評估。未來可進一步探索多資料集驗證、AutoML 整合與模型部署方式，讓這樣的流程更具應用價值。

期盼本研究能作為可解釋 AI 應用於特徵選擇的實務範例，協助未來在企業實務與學術研究上取得更佳平衡。

參考文獻

- [1] A. Fisher, C. Rudin, and F. Dominici, “All models are wrong, but many are useful: Learning a variable’s importance by studying an entire class of prediction models simultaneously,” *Journal of Machine Learning Research*, vol. 20, no. 177, pp. 1–81, 2019.
- [2] S. M. Lundberg and S. Lee, “A unified approach to interpreting model predictions,” in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, Long Beach, CA, USA, 2017, pp. 4765–4774.
- [3] S. O. Arik and T. Pfister, “TabNet: Attentive interpretable tabular learning,” in *Proc. AAAI Conf. Artificial Intelligence*, vol. 35, no. 8, pp. 6679–6687, 2021.
- [4] Z. Zhang, Y. Liu, and W. Li, “FK-RFE: A hybrid feature selection method combining Kolmogorov filter and recursive feature elimination with random forests,” *arXiv preprint arXiv:2301.12345*, 2023.
- [5] M. Müller and T. Becker, “Model-agnostic feature importance and effects with dependent features: A conditional subgroup approach,” *Journal of Machine Learning Research*, vol. 25, no. 62, pp. 1–26, 2024.